

UNIVERSIDAD DEL VALLE DE GUATEMALA

Data Science

Facultad de Ingeniería

Sección 40

Erick Marroquín



Laboratorio 2. Series de Tiempo con LSTM

Joel Jaquez - 23369

Fernando Ruiz - 23065

Kevin Villagran - 23584

GUATEMALA, 2 de agosto 2026

Enlace al repositorio:

<https://github.com/JosFer720/Laboratorio-1-Series-de-Tiempo/tree/Lab2>

Enlace de Informe:

 Informe Laboratorio 2. Series de Tiempo con LSTM

Introducción

Este laboratorio retoma las siete series mensuales construidas entre enero de 2009 y junio de 2026. El primer ejercicio utiliza S0 Total mensual y S1 La Aurora para comparar dos configuraciones de redes Long Short-Term Memory, o LSTM, sobre el mismo corte temporal del estudio anterior. El segundo ejercicio extrae las 22 características canónicas de catch22 y construye una firma comparable para las siete series.

En S0 y S1, la configuración con una ventana de 24 meses, dos capas de 64 unidades y dropout de 0.2 obtuvo el menor RMSE. Para S0 alcanzó 50,988.18 y redujo en 63.46% el RMSE del mejor modelo clásico. Para S1 alcanzó 18,998.20 y redujo en 50.33% el RMSE de ARIMA(1,1,1). O sea, ambas redes representaron mejor la recuperación posterior a la pandemia que los modelos seleccionados en el Laboratorio 1, aunque conservaron una trayectoria más suave que los valores observados.

Según el análisis de catch22, S0 Total mensual y S2 Valle Nuevo son las series más similares, con una distancia estandarizada de 2.86. Además, los dos primeros componentes principales explican el 68.70% de la variabilidad. El análisis de clustering identificó dos grupos (silhouette = 0.3303), aunque la principal diferencia corresponde a S6 Guatemala, debido a la presencia de 42 ceros estructurales registrados desde 2023. En conjunto, estos resultados sugieren que no existe una separación clara entre las estaciones de frontera y las de otros países."

Finalmente, el LSTM enriquecido con las 22 variables catch22 alcanzó un RMSE de 67,734.70, frente a 50,988.18 del LSTM base. El resultado no invalida la utilidad de catch22 para explorar y comparar series. Más bien muestra que una firma global constante puede resumir la dinámica de una serie sin aportar variación nueva entre las ventanas de entrenamiento de esa misma serie.

Datos y diseño experimental

Las series mantienen la definición del Laboratorio 1: S0 representa el total mensual de turistas y excursionistas; S1, S2 y S3 corresponden a La Aurora, Valle Nuevo y San Cristóbal; S4, S5 y S6 corresponden a El Salvador, Estados Unidos y Guatemala. Cada serie contiene 210 meses consecutivos y carece de valores faltantes.

La partición se realiza sobre el eje temporal, nunca de manera aleatoria. Los primeros 147 meses se usan para entrenamiento y los 63 restantes para prueba. El escalamiento se ajusta solamente con entrenamiento. Y así se evita que el modelo conozca la magnitud o la estructura futura antes de producir sus pronósticos recursivos.

Conjunto	Período	Meses	Proporción
Entrenamiento	enero 2009 a marzo 2021	147	70%
Prueba	abril 2021 a junio 2026	63	30%

Tabla 1. Partición temporal común

El criterio principal de selección es RMSE porque penaliza con mayor fuerza los errores grandes y todas las alternativas se evalúan sobre exactamente los mismos meses. MAE complementa la lectura en unidades de viajeros y MAPE expresa el error relativo. En ningún caso AIC o BIC se usan para comparar una red neuronal contra un modelo clásico, pues no representan el mismo tipo de evaluación fuera de muestra.

Metodología LSTM

Representación supervisada

Una LSTM es una red recurrente que conserva y actualiza información mediante compuertas. Esa memoria resulta apropiada para series en las que una observación mensual depende de patrones anteriores. En este laboratorio cada muestra contiene una ventana de meses consecutivos y el objetivo es el mes siguiente. La ventana de 12 meses representa un ciclo anual, mientras que la ventana de 24 meses expone dos ciclos completos.

Configuraciones y entrenamiento

La primera configuración usa una capa LSTM con 50 unidades, ventana de 12 meses y sin dropout. La segunda usa dos capas de 64 unidades, ventana de 24 meses y dropout de 0.2. Ambas se entrenan hasta 100 épocas, con lotes de 16 muestras, semilla 42 y detención temprana. Entonces el tuneo contrasta memoria, profundidad, capacidad y regularización, aunque no constituye una búsqueda exhaustiva de hiperparámetros.

Pronóstico recursivo

El primer mes de prueba se estima a partir de la última ventana observada del entrenamiento. Después cada predicción se incorpora a la ventana para estimar el siguiente mes. O sea, no se alimentan valores reales de prueba en pasos intermedios. Esta estrategia representa un escenario de pronóstico genuino de 63 meses, pero también permite que los errores se acumulen y que la trayectoria se vuelva más suave.

Resultados LSTM para S0 Total mensual

Comparación de configuraciones

Modelo	Configuración	MAE	RMSE	MAPE
LSTM-1capa-w12	ventana 12, 50 unidades, 1 capa, dropout 0.0	85,373	101,263	32.67%
LSTM-2capas-w24	ventana 24, 64 unidades, 2 capas, dropout 0.2	39,077	50,988	23.44%

Tabla 2. Comparación de LSTM para S0

LSTM-2capas-w24 reduce el RMSE de 101,262.75 a 50,988.18, una mejora de 49.65% frente a la configuración de una capa. El MAE baja de 85,372.64 a 39,076.57 y el MAPE de 32.67% a 23.44%. La configuración completa con dos ciclos anuales generaliza mejor, aunque el experimento no permite atribuir la mejora a un hiperparámetro aislado.




Figura 1. S0 Total mensual. Valores observados y pronósticos de las dos configuraciones LSTM.

Comparación con el Laboratorio 1

Modelo	Tipo	MAE	RMSE	MAPE
LSTM-2capas-w24	LSTM	39,077	50,988	23.44%
Prophet	Clásico	132,304	139,549	60.89%

Tabla 3. Mejor LSTM y mejor modelo clásico para S0

El mejor LSTM supera a Prophet en las tres métricas. La reducción relativa del RMSE es 63.46%, mientras que la reducción del MAE es 70.46%. La gráfica muestra que Prophet subestima buena parte de la recuperación posterior a la pandemia. El LSTM también suaviza los picos, pero sigue el cambio de nivel con mayor cercanía.




Figura 2. S0 Total mensual. Mejor LSTM frente a Prophet.

Resultados LSTM para S1 La Aurora

Comparación de configuraciones

Modelo	Configuración	MAE	RMSE	MAPE
LSTM-1capa-w12	ventana 12, 50 unidades, 1 capa, dropout 0.0	17,851	23,958	18.30%
LSTM-2capas-w24	ventana 24, 64 unidades, 2 capas, dropout 0.2	14,873	18,998	18.25%

Tabla 4. Comparación de LSTM para S1

LSTM-2capas-w24 alcanza un RMSE de 18,998.20 y mejora en 20.70% a la alternativa de una capa. El MAE baja 16.68%, mientras que el MAPE cambia solo 0.05 puntos porcentuales. Entonces la elección se apoya principalmente en la mejora consistente de RMSE y MAE, no en una diferencia marginal del MAPE.




Figura 3. S1 La Aurora. Valores observados y pronósticos de las dos configuraciones LSTM.

Comparación con el Laboratorio 1

Modelo	Tipo	MAE	RMSE	MAPE
LSTM-2capas-w24	LSTM	14,873	18,998	18.25%
ARIMA(1,1,1)	Clásico	33,049	38,249	33.08%

Tabla 5. Mejor LSTM y mejor modelo clásico para S1

El LSTM reduce el RMSE de ARIMA(1,1,1) en 50.33%, el MAE en 55.00% y el MAPE en 14.83 puntos porcentuales. ARIMA converge pronto hacia un nivel casi constante y subestima la recuperación. El LSTM se aproxima mejor al nuevo nivel desde 2022, aunque tampoco reproduce todos los picos mensuales.




Figura 4. S1 La Aurora. Mejor LSTM frente a ARIMA(1,1,1).

Lectura conjunta de los modelos LSTM

En las dos series la configuración con ventana de 24 meses y dos capas logra el menor RMSE. El patrón es consistente con la presencia de estacionalidad anual y con un horizonte de prueba dominado por la recuperación posterior a 2020. Tener dos ciclos completos dentro de cada muestra ofrece más contexto para combinar nivel, tendencia y estacionalidad.

Aun así, no puede afirmarse que dos capas sean universalmente mejores. Las configuraciones cambian ventana, unidades, profundidad y dropout al mismo tiempo. Además, el resultado depende de un corte particular que termina cerca del piso pandémico. O sea, la evidencia respalda la selección para S0 y S1 en este período, pero no sustituye una validación temporal más amplia.

Metodología catch22

Idea e importancia

catch22 es un conjunto de 22 características canónicas que resume propiedades de distribución, autocorrelación, periodicidad, dependencia no lineal, entropía, valores atípicos y fluctuaciones. Su utilidad consiste en convertir series completas en vectores del mismo tamaño. Entonces es posible comparar las siete series en un espacio común sin depender solamente de siete gráficas separadas.

Familia	Propiedad resumida	Ejemplos catch22
Distribución	Forma y modos de los valores normalizados	mode_5, mode_10
Dependencia temporal	Escalas de autocorrelación e información mutua	acf_timescale, ami_timescale
Periodicidad	Repetición y contenido espectral	periodicity, centroid_freq
Transiciones	Cambios de estado y persistencia	transition_variance, stretch_high
Complejidad	Entropía, motivos y fluctuaciones	entropy_pairs, dfa, rs_range
Atípicos y predicción	Ubicación de extremos y error local	outlier_timing, forecast_error

Tabla 6. Familias interpretativas de catch22

Extracción, matriz y estandarización

La extracción produce una matriz de 7 filas por 22 columnas. Cada fila corresponde a una serie y cada columna a una característica. Antes del PCA, clustering, correlaciones y distancias, cada columna se estandariza con media cero y desviación estándar uno. Y así una característica con valores numéricamente grandes no domina las comparaciones solo por su escala.




Figura 5. Matriz estandarizada de 22 características para las siete series.

Análisis multivariado de las series

Componentes principales

El primer componente principal explica 45.74% de la variabilidad y el segundo 22.96%. En conjunto conservan 68.70% de la información estandarizada. S6 Guatemala queda muy alejada sobre PC1; S1 La Aurora ocupa el extremo negativo de PC2; S4 El Salvador y S5 Estados Unidos aparecen en la zona positiva de PC2. La proyección simplifica la lectura, pero todavía omite 31.30% de la variabilidad total.




Figura 6. Proyección PCA de las siete series según su firma catch22.

Característica	Carga PC1	Carga PC2	Magnitud
centroid_freq	-0.210	-0.324	0.386
acf_timescale	+0.195	+0.330	0.383
outlier_timing_pos	-0.118	+0.348	0.368
trev	-0.219	+0.286	0.360
ami_timescale	+0.173	-0.315	0.360
acf_first_min	+0.192	-0.298	0.354
whiten_timescale	-0.218	-0.276	0.352
embedding_dist	-0.114	+0.306	0.327

Tabla 7. Características con mayor aporte al plano PCA

Las cargas más grandes corresponden a frecuencia espectral, escalas de autocorrelación, momento de valores atípicos positivos, asimetría temporal e información mutua. O sea, la separación no depende de una sola propiedad, sino de una combinación entre memoria, periodicidad, frecuencia y no linealidad.




Figura 7. Cargas de las características principales sobre PC1 y PC2.

Clustering

K-means se evaluó entre dos y cinco grupos. El mejor silhouette es 0.3303 con dos clusters. El primer grupo contiene S0 a S5 y el segundo contiene solamente S6 Guatemala. El valor de silhouette es moderado, de modo que la separación no debe interpretarse como una taxonomía fuerte.

Serie	Nombre	Categoría	Cluster
S0 total	Total mensual	Total	0
S1 la aurora	La Aurora	Frontera	0
S2 valle nuevo	Valle Nuevo	Frontera	0
S3 san cristobal	San Cristóbal	Frontera	0

Serie	Nombre	Categoría	Cluster
S4 el salvador	El Salvador	País	0
S5 estados unidos	Estados Unidos	País	0
S6 guatemala	Guatemala	País	1

Tabla 8. Asignación de clusters




Figura 8. Selección de k y clusters proyectados sobre los componentes principales.

Correlaciones entre características

La matriz de correlación muestra asociaciones muy altas entre algunas características. Por ejemplo, el primer mínimo de autocorrelación y la escala de información mutua alcanzan una correlación cercana a 0.997. También existe una relación positiva fuerte entre el tiempo de blanqueamiento y el centroide espectral. Sin embargo, solo hay siete observaciones. Entonces estas correlaciones describen este conjunto y no deben tratarse como relaciones universales ni causales.




Figura 9. Correlaciones de Pearson entre las 22 características.

Distancias entre series

Relación	Par de series	Distancia
Más cercana	S0 total / S2 valle nuevo	2.86
Más cercana	S2 valle nuevo / S3 san cristobal	4.53
Más cercana	S2 valle nuevo / S4 el salvador	5.24
Más distante	S5 estados unidos / S6 guatemala	11.05
Más distante	S1 la aurora / S6 guatemala	10.14
Más distante	S2 valle nuevo / S6 guatemala	9.08

Tabla 9. Pares cercanos y distantes en el espacio catch22

S0 Total mensual y S2 Valle Nuevo forman el par más cercano con 2.86. En el extremo contrario, S5 Estados Unidos y S6 Guatemala alcanzan 11.05. S6 también presenta la mayor distancia promedio respecto del resto, 9.51. Y así la atipicidad observada en PCA y clustering queda respaldada por una tercera técnica.




Figura 10. Distancias euclidianas entre las firmas catch22 estandarizadas.

Interpretación y comparación con el EDA

Similitudes, grupos y categorías

S0 y S2 presentan el comportamiento global más similar. Ambas comparten una tendencia ascendente antes de 2020, una ruptura pandémica y una recuperación posterior. No obstante, S0 es un agregado de todas las entradas y S2 es una frontera terrestre. El parecido indica que la dinámica temporal puede ser más importante que la etiqueta administrativa para algunas comparaciones.

Las fronteras no forman un cluster exclusivo y los países tampoco. La Aurora se separa sobre PC2, El Salvador y Estados Unidos ocupan posiciones diferentes, y Guatemala queda aislada. Entonces catch22 no respalda la idea de que todas las series de una misma categoría deban compartir una sola firma temporal.

Serie más atípica

S6 Guatemala es la serie más atípica en PCA, clustering y distancias. Sus características extremas incluyen periodicidad alta, cambios en información mutua, persistencia de valores altos y alteraciones en frecuencia. La causa no debe interpretarse solamente como conducta de viajeros. Desde enero de 2023 Guatemala deja de aparecer como país individual y la serie acumula 42 ceros. O sea, catch22 detecta con claridad una ruptura de registro que ya había sido documentada en el EDA.

Consistencia con tendencia, estacionalidad y pandemia

La comparación es parcialmente consistente con el análisis tradicional. Las siete series mostraban crecimiento previo, impacto de la pandemia y memoria temporal. catch22 conserva esas diferencias mediante características de autocorrelación, periodicidad y fluctuación. Sin embargo, el EDA había mostrado que S5 Estados Unidos era la serie con mayor fuerza estacional, mientras que el espacio catch22 no la agrupa de manera directa con todas las series que también presentan estacionalidad visible.

Esto ocurre porque una firma de 22 variables resume más que tendencia y estacionalidad. También incorpora distribución, entropía, asimetría temporal, transiciones y valores extremos. Y así dos series visualmente estacionales pueden quedar separadas si difieren en memoria, frecuencia o regularidad de las fluctuaciones.

Descubrimientos adicionales

El primer descubrimiento es la cercanía entre S0 y S2. Una inspección visual por separado permitía reconocer choques comunes, pero no mostraba que fueran el par más cercano al combinar 22 dimensiones estandarizadas. El segundo descubrimiento es que la etiqueta de frontera o país explica poco del agrupamiento. El resultado obliga a comparar dinámicas concretas en lugar de asumir homogeneidad dentro de una categoría de negocio.

El tercer descubrimiento es la convergencia de tres técnicas sobre la atipicidad de S6. PCA, K-means y distancias llegan a la misma conclusión desde representaciones distintas. Esa coincidencia fortalece la lectura del quiebre metodológico.

El cuarto descubrimiento es la redundancia potencial entre algunas características, visible en correlaciones cercanas a uno. Esto ayuda a explicar por qué dos componentes principales conservan una proporción considerable de la variabilidad a pesar de partir de 22 columnas.

Modelo LSTM con variables catch22

Diseño sin fuga temporal

El experimento se realiza sobre S0 y conserva la arquitectura ganadora: ventana de 24 meses, dos capas de 64 unidades, dropout de 0.2, hasta 100 épocas y lotes de 16. Cada paso de la entrada contiene el valor mensual escalado y las 22 características catch22 estandarizadas de S0, por lo que la forma cambia de 24 por 1 a 24 por 23.

Para evitar información futura, las firmas se recalculan con los 147 meses de entrenamiento de las siete series y se estandarizan entre esas siete filas. El vector de S0 se mantiene constante dentro de todas sus ventanas. Entonces el experimento incorpora contexto catch22 sin usar ningún valor real de los 63 meses de prueba.

Modelo	Variables por paso	MAE	RMSE	MAPE
LSTM-2capas-w24	1	39,077	50,988	23.44%
LSTM-catch22-contexto-w24	23	55,256	67,735	29.16%

Tabla 10. LSTM base y LSTM con contexto catch22

Resultado y discusión

El LSTM con catch22 alcanza un RMSE de 67,734.70, frente a 50,988.18 del modelo base. El error aumenta 32.84%. El MAE pasa de 39,076.57 a 55,256.39, un aumento de 41.41%, y el MAPE pasa de 23.44% a 29.16%. Por lo tanto, la incorporación de variables catch22 no mejora el pronóstico de S0 en este diseño.

La firma catch22 es constante para todas las ventanas de una misma serie. O sea, aumenta la dimensionalidad de la entrada, pero no agrega variación entre muestras. La red debe estimar más pesos con solo 123 ventanas supervisadas. Esto explica por qué una representación muy útil para comparar series puede ser menos útil como predictor estático dentro de una sola serie.




Figura 11. S0 Total mensual. Pronóstico recursivo del LSTM con contexto catch22.

Limitaciones

Las redes LSTM se comparan mediante dos configuraciones, no mediante una búsqueda exhaustiva. Como varios hiperparámetros cambian al mismo tiempo, no es posible aislar el efecto individual de la ventana, las unidades, la profundidad o el dropout.

El corte temporal deja el entrenamiento cerca del piso de la pandemia y la prueba contiene la recuperación completa. Entonces las comparaciones describen un cambio de régimen especialmente exigente y no garantizan el mismo orden de modelos en otro horizonte.

El análisis catch22 dispone de siete filas. PCA y distancias son descriptivos, pero el silhouette moderado y las correlaciones calculadas con pocas observaciones requieren cautela. Además, S6 contiene ceros de origen metodológico, por lo que parte de su atipicidad representa calidad y granularidad de registro, no solo conducta temporal.

El LSTM con catch22 usa una firma global constante por serie. Una extensión futura podría entrenar conjuntamente varias series o construir características móviles con una estrategia de validación específica. Sin embargo, esa extensión necesitaría controlar la estabilidad del pronóstico recursivo y la cantidad reducida de muestras.

Conclusiones

Las configuraciones LSTM evaluadas superan a los mejores modelos clásicos en S0 y S1. En ambas series la ventana de 24 meses y dos capas produce el menor RMSE. La ventaja es especialmente clara durante la recuperación posterior a la pandemia, donde Prophet y ARIMA subestiman el nuevo nivel con mayor intensidad.

catch22 permite resumir siete trayectorias heterogéneas en una matriz común y compararlas desde varias perspectivas. S0 y S2 son las más parecidas, S6 es la más atípica y las categorías de frontera o país no generan grupos naturales bien separados. Entonces la similitud temporal no coincide necesariamente con la clasificación administrativa.

Los componentes principales se apoyan sobre memoria, periodicidad, frecuencia, información mutua y comportamiento de valores atípicos. Esta combinación aporta hallazgos que no eran evidentes al observar tendencia y estacionalidad por separado. Y así catch22 complementa el EDA tradicional en vez de reemplazarlo.

El LSTM con contexto catch22 no supera al LSTM base. Este resultado es útil porque distingue dos usos de las mismas variables: son informativas para comparar series, pero una firma constante no necesariamente mejora la predicción de una sola trayectoria. La evaluación fuera de muestra sigue siendo el criterio decisivo.

Referencias

- Hochreiter, S., y Schmidhuber, J. (1997). Long short-term memory. *Neural Computation*, 9(8), 1735-1780. <https://doi.org/10.1162/neco.1997.9.8.1735>
- Lubba, C. H., Sethi, S. S., Knaute, P., Schultz, S. R., Fulcher, B. D., y Jones, N. S. (2019). catch22: CAnonical Time-series CHaracteristics. *Data Mining and Knowledge Discovery*, 33, 1821-1852. <https://doi.org/10.1007/s10618-019-00647-x>
- Universidad del Valle de Guatemala. (2026). Deep learning. Material de clase de CC3084 Data Science.
- Universidad del Valle de Guatemala. (2026). Fuentes y preparación de datos. Material de clase de CC3084 Data Science.
- Universidad del Valle de Guatemala. (2026). Series de tiempo. Material de clase de CC3084 Data Science.