

UNIVERSIDAD DEL VALLE DE GUATEMALA

Data Science

Facultad de Ingeniería

Sección 40

Erick Marroquín



Laboratorio 1. Series de Tiempo. Avance

Joel Jaquez - 23369

Fernando Ruiz - 23065

Kevin Villagran - 23584

GUATEMALA, 23 de julio 2026

Enlace al repositorio:

<https://github.com/JosFer720/Laboratorio-1-Series-de-Tiempo.git>

Resumen del avance:

En este avance se exploró la información mensual de viajeros internacionales que ingresaron a Guatemala entre enero de 2009 y junio de 2026. Después de revisar la calidad de los datos, se construyeron las series utilizando únicamente Turistas y Excursionistas, debido a que estas categorías mantienen un criterio más consistente a lo largo del tiempo. El análisis muestra un crecimiento antes de 2020, una caída extraordinaria durante la pandemia y una recuperación gradual posterior. También se estudiaron con mayor detalle la serie total y los ingresos por La Aurora, identificando tendencia, comportamiento estacional y la necesidad de transformar y diferenciar ambas series antes de modelarlas.

Descripción del conjunto de datos:

El conjunto de datos utilizado contiene información mensual sobre el ingreso de viajeros internacionales a Guatemala. El período disponible comienza en enero de 2009 y finaliza en junio de 2026, para un total de 210 meses consecutivos y 161,036 registros. Es importante considerar que la información de 2026 llega únicamente hasta junio, por lo que ese año no debe compararse directamente con años completos.


La base se encuentra organizada de manera que cada fila representa una combinación específica de mes, vía de ingreso, frontera, país de residencia, región y tipo de viajero. La variable Viajero contiene la cantidad de personas registradas para cada una de estas combinaciones. Esta estructura permite analizar el comportamiento general de los ingresos y también construir series más específicas por frontera o país de residencia.

Variable	Descripción
Año	Año al que corresponde el registro.
Mes cod	Código numérico del mes (1-12).
Mes	Nombre del mes.
Vía	Medio de ingreso (aérea, terrestre, marítima).
Frontera	Puesto fronterizo o aeropuerto de ingreso.
País	País de residencia del viajero.
Región	Clasificación regional del país de residencia.
Región dos	Segunda clasificación geográfica de los países.
Regiones OMT	Clasificación regional según la Organización Mundial del Turismo.
MCEO	Clasificación complementaria del mercado de residencia.
Agrupación Residencia	Grupo del lugar de residencia del viajero.
Tipo de Viajero	Categoría (turista, excursionista, etc.).
Viajero	Cantidad de viajeros registrados.

Análisis Exploratorio:

Comportamiento mensual general:


Entre 2009 y 2019 se observa un crecimiento general en la cantidad de viajeros. También aparecen aumentos y disminuciones que se repiten aproximadamente en los mismos meses de cada año, lo que sugiere un comportamiento estacional. En 2020 la trayectoria cambia por completo: la serie cae de manera abrupta debido al cierre de fronteras y alcanza su valor más bajo en mayo, con 9,779 viajeros. Después comienza una recuperación gradual, aunque el comportamiento posterior ya no es igual al observado antes de la pandemia.



(Figura 1. Total mensual de Turistas y Excursionistas entre enero de 2009 y junio de 2026.)

Principales países de residencia:


El Salvador es el principal país de residencia dentro de los registros analizados. Guatemala también aparece con una cantidad muy alta, pero corresponde principalmente a residentes guatemaltecos que regresan al país, por lo que no debe interpretarse como turismo extranjero. Por esta razón, las tres series por país seleccionadas para el laboratorio corresponden a El Salvador, Estados Unidos y Honduras. En general, el gráfico muestra que los viajeros se concentran principalmente en países cercanos y en Estados Unidos.



(Figura 2. Diez principales países de residencia según el total acumulado de Turistas y Excursionistas.)

Regiones de procedencia:


Centroamérica concentra aproximadamente el 71.3% de los viajeros, mientras que América del Norte representa cerca del 19.6%. En conjunto, ambas regiones explican más del 90% del total. Esto muestra que la cercanía geográfica tiene un peso importante en el ingreso de visitantes a Guatemala. El valor cero encontrado en la variable regional se interpretó como un registro sin clasificación y se excluyó únicamente del ranking, sin eliminar a esos viajeros del total.



(Figura 3. Distribución acumulada de viajeros por región de residencia.)

Vías y fronteras de ingreso:

La vía terrestre representa el 59.1% de los ingresos y la vía aérea el 40.7%. Aunque el transporte terrestre tiene la mayor participación en conjunto, La Aurora es el punto de ingreso individual con más viajeros. Le siguen Valle Nuevo y San Cristóbal, ambas fronteras terrestres. La selección de estas tres fronteras permite comparar el comportamiento de un ingreso aéreo con dos de los principales ingresos terrestres.




(Figura 4. Participación por vía y principales fronteras de ingreso.)

Nulos y duplicados:

Durante la revisión del conjunto de datos no se encontraron valores faltantes ni filas completamente duplicadas. Se identificaron 22 repeticiones al considerar la clave formada por la fecha, vía, frontera, país y tipo de viajero. Sin embargo, estas observaciones se diferencian en la variable Agrupación Residencia, por lo que representan desagregaciones válidas y no errores de duplicación. En total, estas repeticiones involucran 42 filas, las cuales se conservaron para evitar la pérdida de viajeros registrados.

Valores atípicos y pandemia:

La regla estadística utilizada identifica únicamente a diciembre de 2019 como un valor atípico, debido a su cantidad especialmente alta de viajeros. Los valores bajos de la pandemia son extraordinarios cuando se observa la serie en el tiempo, pero no quedan fuera de los límites calculados por esta regla. Esto demuestra que una observación puede ser importante por su contexto histórico aunque un método automático no la clasifique como atípica. Ninguno de estos datos se eliminó porque representan movimientos reales.



(Figura 5. Revisión de valores atípicos y ubicación del período de pandemia.)

Estadísticos descriptivos:


Estadístico	Valor
Media	222,438
Mediana	227,606
Desviación Estándar	84,725
Mínimo	9,779
Máximo	449,114

En promedio se registraron 222,438 viajeros mensuales. La media y la mediana son relativamente cercanas, lo que indica que el centro de la distribución no está dominado completamente por unos pocos meses extremos. Sin embargo, la desviación estándar de 84,725 viajeros muestra que existe una variación considerable entre meses. Esta variación se

explica tanto por las temporadas del año como por eventos extraordinarios, especialmente la pandemia.

Cambio en el registro a partir de 2023:

Al incluir todos los tipos de viajero aparece un cambio muy marcado a partir de 2023. Este movimiento no debe interpretarse directamente como una caída real del turismo, porque coincide con una modificación en la forma de clasificar los registros. En cambio, la serie formada por Turistas y Excursionistas mantiene una continuidad más razonable.



(Figura 6. Comparación entre la serie utilizada y la serie que incluye todos los tipos de viajero.)

Construcción de las series:

A partir de los datos previamente depurados se construyeron siete series de tiempo con frecuencia mensual, es decir, con doce observaciones por año. La serie S0 representa el total mensual de viajeros, mientras que las series S1, S2 y S3 corresponden a los ingresos registrados por las fronteras La Aurora, Valle Nuevo y San Cristóbal, respectivamente. Por su parte, las series S4, S5 y S6 representan a los viajeros procedentes de El Salvador, Estados Unidos y Honduras. Todas las series abarcan el período comprendido entre enero de 2009 y junio de 2026. Para este avance se analizaron detalladamente la serie total S0 y la serie de La Aurora S1.


Tabla de las series analizadas:

Serie	Inicio	Fin	Frecuencia	Entrenamiento	Prueba
S0 — Total mensual	Enero de 2009	Junio de 2026	Mensual (12 obs/año)	Enero de 2009 – marzo de 2021 (147 meses)	Abril de 2021 – junio de 2026 (63 meses)
S1 — La Aurora	Enero de 2009	Junio de 2026	Mensual (12 obs/año)	Enero de 2009 – marzo de 2021 (147 meses)	Abril de 2021 – junio de 2026 (63 meses)

Análisis de S0: total mensual

Comportamiento y partición:


La serie total muestra crecimiento y variaciones anuales antes de la pandemia. La caída de 2020 rompe ese comportamiento y modifica tanto el nivel como la variación de la serie. También es importante observar que el conjunto de entrenamiento termina en marzo de 2021, cuando la recuperación apenas estaba comenzando. Por lo tanto, gran parte de la recuperación queda dentro del período de prueba y podría ser difícil de predecir utilizando solamente el comportamiento anterior.



(Figura 7. Serie total y separación temporal entre entrenamiento y prueba.)

Tendencia y estacionalidad:


La descomposición permite observar por separado el movimiento general, el patrón anual y las variaciones que no quedan explicadas por esos dos componentes. La tendencia aumenta hasta 2019 y luego cae con fuerza durante 2020. El componente estacional confirma que existen meses que suelen registrar niveles más altos o más bajos. Por último, los residuos crecen alrededor de la pandemia, porque se trata de un evento que el comportamiento habitual de la serie no podía representar.



(Figura 8. Descomposición de la serie total durante el período de entrenamiento.)

Cambio en la media y variabilidad

La media móvil cambia claramente con el paso del tiempo, por lo que la serie no se mantiene alrededor de un mismo nivel. La variación también aumenta y disminuye según el período observado. Al aplicar el logaritmo, los picos muy altos se reducen y los cambios se pueden comparar de una manera más proporcional. Sin embargo, la transformación no hace desaparecer la caída de la pandemia, porque sigue siendo un cambio real en el comportamiento de la serie.




(Figura 9. Media y variación móvil de la serie total antes y después de aplicar logaritmo.)

Valores de las pruebas ADF y KPSS

En la serie original, la prueba ADF obtuvo un estadístico de -2.364 y un valor p de 0.152, por lo que no existe evidencia suficiente para considerarla estacionaria. El logaritmo por sí solo tampoco resolvió el problema, con un valor p de 0.116. Después de aplicar la primera diferencia del logaritmo, el valor p de ADF disminuyó a 0.028 y KPSS presentó un valor p igual o mayor que 0.10. Ambos resultados indican que la serie alcanza un comportamiento más estable, por lo que se propone utilizar $d=1$.

ACF, pruebas y diferenciación:

En la serie original, la relación entre un mes y los meses anteriores permanece alta durante varios rezagos. Esto coincide con lo observado en las gráficas y es que la serie tiene memoria, tendencia y un patrón anual. Después de calcular la primera diferencia del logaritmo, las relaciones disminuyen y la serie se comporta de una manera más estable. Las pruebas ADF y KPSS respaldan esta decisión, por lo que para S0 se propone utilizar una diferencia regular, es decir, $d = 1$. La diferencia estacional $D = 1$ se conservará como una posibilidad para evaluar posteriormente, pero todavía no se considera una decisión definitiva.




(Figura 10. Relación temporal de S0 antes y después de aplicar las diferencias.)

Análisis de S1: ingresos por La Aurora

Comportamiento y partición:


Los ingresos por La Aurora presentan un crecimiento gradual y picos que se repiten cada año antes de 2020. Durante el cierre de fronteras la cantidad cae prácticamente a cero y alcanza un mínimo de 484 viajeros en abril de 2020. La recuperación ocurre principalmente dentro del conjunto de prueba, por lo que esta serie presenta el mismo desafío que la serie total: el entrenamiento termina antes de recuperar su comportamiento habitual.



(Figura 11. Serie mensual de La Aurora y separación entre entrenamiento y prueba.)

Tendencia y estacionalidad:


La descomposición muestra una tendencia creciente antes de la pandemia y un patrón anual bastante visible. La estacionalidad de La Aurora es un poco más marcada que la de la serie total, lo que indica que ciertos meses tienen un efecto más repetitivo en los ingresos por el aeropuerto. Los residuos aumentan alrededor de 2020 porque el cierre aéreo produjo un comportamiento muy diferente al esperado.



(Figura 12. Descomposición de los ingresos por La Aurora durante el entrenamiento.)

Cambio en la media y variabilidad:

Tanto el promedio móvil como la variación cambian con el tiempo, especialmente alrededor de la pandemia. La transformación logarítmica ayuda a reducir la diferencia entre los meses de mayor y menor movimiento y permite observar mejor los cambios proporcionales. Aun así, el mínimo de 2020 continúa siendo claramente extraordinario y debe mantenerse como parte de la historia de la serie.




(Figura 13. Media y variación móvil de La Aurora en escala original y logarítmica.)

Valores de las pruebas ADF y KPSS:

Para La Aurora, la prueba ADF aplicada a la serie original obtuvo un estadístico de -2.370 y un valor p de 0.150, mientras que en escala logarítmica el valor p fue de 0.273. Estos resultados indican que el logaritmo por sí solo no es suficiente. Después de aplicar la primera diferencia del logaritmo, ADF obtuvo un valor p de 0.027 y KPSS un valor p igual o mayor que 0.10. Por lo tanto, ambas pruebas respaldan el uso de $d=1$.

ACF, pruebas y diferenciación

En la serie original, los valores de un mes guardan una relación fuerte con varios meses anteriores. Después de aplicar la primera diferencia del logaritmo, esa relación disminuye y el comportamiento se vuelve más estable. Los resultados de ADF y KPSS coinciden en que esta transformación es adecuada, por lo que se propone $d=1$. Debido al patrón anual de La Aurora, también se evaluará $D=1$ durante la etapa de modelado.



(Figura 14. Relación temporal de La Aurora antes y después de aplicar las diferencias.)

Comparación y conclusiones del avance:

Las dos series analizadas presentan crecimiento antes de 2020, un comportamiento estacional y una ruptura importante durante la pandemia. Ninguna mantiene una media constante en su forma original. En ambos casos, el logaritmo ayuda a controlar los cambios de escala, pero es necesario aplicar una primera diferencia para obtener un comportamiento más estable. Por esta razón se propone $d=1$ para S_0 y S_1 , mientras que $D=1$ se mantendrá como candidato para la etapa de modelado. La Aurora presenta una estacionalidad un poco más marcada que la serie total. Finalmente, debe considerarse que el entrenamiento termina durante una recuperación todavía incompleta, lo que podría dificultar las predicciones sobre el conjunto de prueba.